

**JobPath: Marco Metodológico Integrado KDD–CRISP-DM para la Minería de
Trayectorias Laborales**

Johan Steven Lopez Ordoñez, Juan Sebastián Rueda Ortiz y Jairo Esteban Salgado Tinoco

Ingeniería de Sistemas, Corporación Universitaria Minuto de Dios (UNIMINUTO)

Minería de Datos

Prof. Esteban Ernesto Morales Castro

14 de septiembre de 2026

Contenido

JobPath: Marco Metodológico Integrado KDD–CRISP-DM para la Minería de Trayectorias	
Laborales.....	3
Síntesis del Estado del Proyecto	4
Objetivo y Preguntas de Investigación	4
Fuentes de Datos y Cifras Clave.....	4
Tabla 1	5
Marco Metodológico Integrado: KDD y CRISP-DM.....	6
Tabla 2	6
Fases Completadas.....	7
Comprensión del Negocio y Selección.....	7
Comprensión de los Datos y Diagnóstico.....	7
Preparación de los Datos y Preprocesamiento	8
Plan de Acción para Fases Pendientes	8
Transformación de los Datos	8
Modelado y Minería de Secuencias	9
Evaluación e Interpretación	9
Despliegue y Conocimiento.....	9
Conclusiones y Sigüientes Pasos	10
Referencias.....	11

JobPath: Marco Metodológico Integrado KDD–CRISP-DM para la Minería de Trayectorias Laborales

El presente documento tiene como objetivo principal contextualizar formalmente el proyecto JobPath dentro de las fases de las metodologías Knowledge Discovery in Databases (KDD) y Cross-Industry Standard Process for Data Mining (CRISP-DM). Este proyecto se centra en el análisis de trayectorias laborales utilizando el conjunto de datos JobHop v2 (Ghaffari et al., 2026; Hugging Face, 2026), el cual ha sido enriquecido con la taxonomía ESCO v1.2.1 (Comisión Europea, 2022). Asimismo, se estructura un plan de acción detallado para las fases metodológicas faltantes, orientado a cumplir con los más altos estándares de calidad académica y técnica en el campo de la minería de datos.

Para el desarrollo de este análisis, se han establecido restricciones metodológicas inmutables. En primer lugar, los datos principales extraídos de JobHop provienen de Flandes, Bélgica; por consiguiente, el enfoque del proyecto recae exclusivamente en las trayectorias laborales como fenómeno, sin buscar generalizaciones o focalizaciones geográficas ajenas a su origen. En segundo lugar, se ha determinado el uso de banderas analíticas (tales como *es_unknown_ocupacion*, *es_rescatado* y *es_vigente*) como estrategia central para el manejo de datos ausentes o censurados, descartando por completo las técnicas de imputación tradicional o la eliminación de información estructural. Finalmente, por decisión documentada del equipo investigador, el formato de almacenamiento de los datos procesados es exclusivamente de valores separados por comas (CSV), habiéndose eliminado los formatos Parquet de las fases de cruce.

Síntesis del Estado del Proyecto

Objetivo y Preguntas de Investigación

El propósito central de la investigación radica en analizar el desarrollo de la trayectoria laboral de los individuos tras culminar su formación académica. Específicamente, se busca determinar si los primeros empleos mantienen relación con el área de estudio, la frecuencia de cambios de sector y los patrones de transición laboral emergentes. A nivel técnico, la interrogante principal se define como: ¿Qué patrones de transición ocupacional pueden identificarse en trayectorias laborales posteriores a la formación académica? Es fundamental destacar que el proyecto adopta una postura exploratoria y de descubrimiento, sin asumir a priori que la correspondencia entre los estudios y el empleo resulte imperativamente en una trayectoria superior.

Fuentes de Datos y Cifras Clave

La selección de fuentes se concentró en dos recursos principales. El conjunto de datos JobHop v2 actúa como la fuente primaria para la estructuración de trayectorias, aportando información longitudinal sobre el individuo, la temporalidad, el código ocupacional y el nivel educativo. Por su parte, la taxonomía ESCO v1.2.1 cumple un rol de enriquecimiento semántico, traduciendo los códigos ocupacionales en nombres formales y grupos de la Clasificación Internacional Uniforme de Ocupaciones (ISCO-08). El cruce de estas fuentes evidenció que 2,855 de los 2,873 códigos únicos emparejaron directamente, cubriendo aproximadamente el 93.1 % de las filas, lo cual garantizó el mantenimiento de una estructura sólida sin la multiplicación de registros. Las métricas de calidad y dimensiones del conjunto actual de datos (conjunto de prueba y validación) se detallan en la Tabla 1, evidenciando la integridad del procesamiento realizado.

Tabla 1*Cifras Ancla del Proyecto JobPath (Dataset test+val)*

Métrica Analizada	Valor Verificado	Descripción
Integrado crudo (<i>empleos.csv</i>)	376,567 filas × 11 columnas	Abarca a 71,061 personas. Representa la línea base tras la integración.
Integrado limpio (<i>empleos_limpio.csv</i>)	376,567 filas × 14 columnas	Incluye las 11 columnas base más 3 banderas operativas.
Duplicados	0	Se reportan cero registros exactos y cero duplicados por llave primaria.
Duración trimestral inclusiva	Mediana de 5	Rango intercuartílico (IQR) con Q1=2 y Q3=11. Máximo observado de 160.
Límite de valores atípicos (IQR)	Límite superior de 24.5	35,477 filas (pertenecientes a 24,687 personas) superan el límite y son conservadas como cola larga.
Banderas de control	25,805; 2,499; 18,956	Distribuidas en ocupación desconocida, rescatada y empleo vigente, respectivamente.

Nota. Los valores reflejan la exactitud del tratamiento sin pérdida de datos, pues se eliminaron 0 filas por fechas futuras. La recategorización del nivel educativo consolidó 42,807 registros bajo la etiqueta “No reportado” (valores nulos y celdas vacías).

Marco Metodológico Integrado: KDD y CRISP-DM

La articulación de las metodologías KDD y CRISP-DM permite establecer un flujo de trabajo estructurado, desde la comprensión inicial hasta el despliegue del conocimiento. La Tabla 2 ilustra la equivalencia de fases entre ambos marcos y su estado de avance en el contexto del proyecto.

Tabla 2

Estado de Fases Metodológicas en JobPath

Fase CRISP-DM	Fase KDD	Estado de Ejecución	Entregable Clave
1. Comprensión del negocio	1. Selección	Completado	Objetivos y fuentes seleccionadas.
2. Comprensión de datos	2. Preprocesamiento (diagnóstico)	Completado	Diagnóstico, umbrales IQR y clasificación de ausencias.
3. Preparación de datos	2. Preprocesamiento y 3. Transformación	Parcial	Pipeline de limpieza validado; pendiente generación de secuencias.
4. Modelado	4. Minería	Pendiente	Selección algorítmica de transiciones.
5. Evaluación	5. Interpretación	Pendiente	Validación de frecuencia y consistencia.
6. Despliegue	6. Conocimiento	Pendiente	Informe final de trayectoria laboral.

Nota. El estado “Parcial” de la tercera fase obedece a la naturaleza iterativa de CRISP-DM, donde el preprocesamiento ha finalizado, pero la transformación temporal permanece en estructuración.

Fases Completadas

Comprensión del Negocio y Selección

Esta fase inicial se encuentra completada. Se ha consolidado el objetivo de minería y las preguntas de investigación. Se seleccionaron formalmente los repositorios JobHop v2 y ESCO v1.2.1, descartando de manera justificada aquellos elementos anexos (como competencias específicas o la taxonomía ISCED-F) que no aportaban un valor directo e inmediato al análisis de transiciones ocupacionales.

Comprensión de los Datos y Diagnóstico

La etapa de comprensión y diagnóstico se ejecutó satisfactoriamente sobre el archivo integrado actual. El diagnóstico verificó un total de 376,567 filas correspondientes a 71,061 individuos. Durante este proceso, se identificaron y clasificaron los datos ausentes bajo el rigor de la teoría estadística. En esta iteración, no se detectaron registros con fechas de finalización futuras (posteriores al año 2026), por lo que hubo cero eliminaciones bajo el criterio de valores faltantes completamente al azar (MCAR) por error de captura. Asimismo, los 18,956 registros reportados en la fuente como empleos vigentes se clasificaron formalmente como casos de censura por la derecha, evitando su alteración para no distorsionar las duraciones reales en las trayectorias.

El análisis de valores atípicos demostró que la duración de los empleos presenta una asimetría positiva representativa de la estabilidad laboral. Aplicando el método de Tukey, se estableció un límite superior de 24.5 trimestres. Los 35,477 registros que superaron este umbral fueron conservados intencionalmente, reconociendo que las trayectorias prolongadas constituyen una señal demográfica válida y no una aberración numérica.

Preparación de los Datos y Preprocesamiento

El preprocesamiento se abordó exhaustivamente. Como resultado del flujo de depuración técnica, se generó un archivo consolidado final que mantuvo su dimensión exacta de 376,567 filas. En lugar de aplicar imputaciones estadísticas clásicas que pudieran sesgar los comportamientos longitudinales, se establecieron banderas indicadoras lógicas y se recategorizaron 42,807 valores nulos y vacíos en el nivel educativo bajo la etiqueta estructurada de “No reportado”.

Adicionalmente, la exploración analítica preliminar identificó que el 18.3 % de las transiciones conservan el grupo ocupacional; no obstante, se advierte de manera documentada que esta métrica de comportamiento fue calculada como línea base inicial sobre la versión anterior del conjunto de entrenamiento y deberá recalcularse rigurosamente sobre el actual conjunto integrado de prueba y validación para el inicio de la fase de modelado.

Plan de Acción para Fases Pendientes

Transformación de los Datos

La transformación de datos, orientada hacia el modelado secuencial, se centrará en convertir las experiencias laborales aisladas en vectores temporales coherentes por individuo. El plan de acción proyecta la construcción de estas secuencias resolviendo lógicamente los

solapamientos laborales y la permanencia de empleos bajo censura temporal. Además, se definirá explícitamente la unidad de análisis y se implementará la codificación algorítmica requerida, garantizando en todo momento la invariabilidad estructural del archivo de origen.

Modelado y Minería de Secuencias

La selección de la técnica de modelado se efectuará empíricamente basándose en la topología resultante de los datos transformados. Entre las estrategias metodológicas candidatas se contempla el análisis mediante matrices de transición de primer orden, la minería de patrones recurrentes y el agrupamiento por similitud de secuencias. Para la ejecución de esta fase, será imperativo resolver el manejo matemático de los nodos ocupacionales no clasificados y estandarizar los parámetros algorítmicos.

Evaluación e Interpretación

Durante la fase interpretativa, se validará la utilidad empírica de los patrones descubiertos respecto a las preguntas iniciales. Se evaluará la frecuencia de soporte (actualizando las líneas base), la consistencia intergrupar según el nivel educativo y la robustez analítica. Todo hallazgo se documentará estrictamente señalando el dato estadístico, su interpretación técnica y sus limitaciones; reiterando constantemente que las secuencias sociolaborales observadas en la región belga estudiada no establecen preceptos de causalidad generalizables.

Despliegue y Conocimiento

Como etapa culminante de las metodologías, se consolidará el conocimiento descubierto mediante una caracterización formal de los vectores de transición ocupacional predominantes. Se documentará el ciclo de trabajo de extremo a extremo, asegurando la reproducibilidad técnica total del experimento a través de la gestión de entornos y rutas de ejecución controladas. Se

presentará, finalmente, un informe académico unificado que exponga con claridad el valor de la minería de secuencias aplicada a las ciencias laborales.

Conclusiones y Sigüientes Pasos

El proyecto JobPath ha finalizado satisfactoriamente las etapas fundacionales correspondientes a la integración, el diagnóstico profundo y el preprocesamiento de la información. Las acciones investigativas inmediatas se orientan a la transformación definitiva de las trayectorias en estructuras de datos secuenciales; un requisito ineludible que posibilitará el inicio del modelado de minería. La adopción de variables indicadoras, la correcta categorización de las ausencias y el riguroso respeto por la distribución original de las duraciones garantizan una plataforma de datos de 376,567 registros altamente confiable para las fases analíticas venideras.

Referencias

- Comisión Europea. (2022). *European Skills, Competences, Qualifications and Occupations (ESCO) v1.2.1* [Conjunto de datos]. Portal de datos abiertos de la Unión Europea.
- Ghaffari, S., et al. (2026). *JobHop v2: A large-scale career trajectory dataset from unstructured resumes*. arXiv. <https://arxiv.org/abs/2607.11715>
- Hugging Face. (2026). *aida-ugent/JobHop v2 dataset* [Conjunto de datos]. <https://huggingface.co/datasets/aida-ugent/JobHop>